

Raport Progresi — Tema e Masterit

Klasifikimi i Mbeturinave përmes Imazheve duke përdorur CNN

Studenti: Era Kastrati

Mentori: Bertan Karahoda

Data: Korrik 2026

Statusi: Faza eksperimentale e përfunduar — gati për dokumentim

1. Përmbledhje

Ky raport përshkruan punën e realizuar deri tani në kuadër të temës së masterit mbi klasifikimin automatik të mbeturinave duke përdorur rrjete nervore konvolucionale (CNN). Janë realizuar **11 eksperimente** sistemike, duke filluar nga një CNN e ndërtuar nga zero deri te fine-tuning i avancuar i modeleve të pre-trajnuara. Rezultati final arrin **92.17% saktësi** mbi një dataset real me 600 foto të mbledhura nga ambienti i përditshëm.

2. Dataset-et e Përdorura

2.1 Dataset trajnimit (TrashNet — bazë)

Parametri	Vlera
Burimi	TrashNet (Kaggle)
Klasa	6: cardboard, glass, metal, paper, plastic, trash

Parametri	Vlera
Imazhe totale	2,527
Ndarja	80% trajnim (2,022) / 20% validim (505)
Dimensionet	512×384 px (risize në 224×224)
Karakteristikë	Imazhe në kushte të kontrolluara, sfond i bardhë

Shpërndarja e klasave (TrashNet):

Klasa	Imazhe
cardboard	403
glass	501
metal	410
paper	594
plastic	482
trash	137 ← e pabalancuar
TOTAL	2,527

2.2 Dataset-et shtesë (fine-tuning)

Dataset	Imazhe	Qëllimi
TACO (Trash Annotations in Context)	3,601 crops	Imazhe reale me objekte të izoliara
RealWaste	3,905	Imazhe nga ambienti i deponisë
Household Waste	7,500	Imazhe shtëpiake, objekte të zakonshme
Garbage Classification v2	~17,000	Dataset i larmishëm real-world

2.3 Real Test Dataset (i mbajtur jashtë trajnimit)

Parametri	Vlera
Qëllimi	Testim final — kurrë i përdorur për trajnim
Imazhe totale	600
Imazhe për klasë	100 (të balancuara)
Mbledhja	Foto reale + burime interneti, kushte jo të kontrolluara
Karakteristikë	Sfonde të ndryshme, ndriçim variues, kënde të ndryshme

3. Arkitektura dhe Qasja

3.1 CNN bazike (nga zero)

Ndërtuar me shtresa konvolucionale, MaxPooling dhe Dense — pa pesha të pre-trajnuara. Shërbeu si *baseline* për krahasim.

3.2 Transfer Learning

Janë përdorur dy arkitektura: - **MobileNetV2** — model i lehtë, i shpejtë - **EfficientNetB0** — balancë optimale mes saktësisë dhe kompleksitetit

Strategjia e trajnimit: 1. *Feature Extraction* — shtresat bazë të ngrira, trajnohen vetëm shtresat e fundit 2. *Fine-Tuning* — zhbllokimi i shtresave të sipërme me `lr=1e-5` (learning rate i ulët për të shmangur harrimin katastrofik) 3. *Callbacks*: `EarlyStopping(patience=5)`, `ModelCheckpoint(monitor=val_accuracy)`

3.3 Data Augmentation

Aplikuar gjatë trajnimit: - Kthim horizontal (flip) - Rrotullim $\pm 20^\circ$ - Zoom $\pm 15\%$ - Ndryshim ndriçimi

3.4 Test-Time Augmentation (TTA)

Gjatë inferimit, çdo imazh paraqitet nga **5 pamje të ndryshme** dhe probabilitetet mësohen duke i mesatarizuar — kjo redukton ndjeshmërinë ndaj kornizimit dhe sfondit.

4. Eksperimentet (EXP-001 deri EXP-011)

4.1 Tabela përmbledhëse e eksperimenteve

ID	Modeli	Val TrashNet	Real-World (v2)	Shënim
EXP-001	CNN Baseline (nga zero)	56.44%	—	Baseline
EXP-002	MobileNetV2 Transfer Learning	87.13%	—	+30.69pp vs CNN
EXP-003	EfficientNetB0 Transfer Learning	89.90%	78.33%	+2.77pp vs MobileNet
EXP-004	EfficientNetB0 + Augmentation	89.70%	82.67%	+4.34pp real-world
EXP-005	+ Fine-tune TACO	92.87%	—	Rekord TrashNet
EXP-006	+ Background Removal (rembg)	—	—	Rezultat negativ -2.56pp
EXP-007	+ Fine-tune RealWaste	91.29%	—	+2.57pp real-world
EXP-008	+ Fine-tune Household	90.50%	88.83%	+10.50pp vs bazë
EXP-009	+ TTA	90.50%	88.83% (TTA)	+5pp pa ritrainim
EXP-010		—	—	

ID	Modeli	Val TrashNet	Real- World (v2)	Shënim
	Ensemble 3 modele + TTA			Rezultat negativ −3.85pp
EXP-011	+ Fine-tune Garbage v2	89.90%	92.17%	BEST

4.2 Progresi real-world (dataset v2, TTA)

EfficientNetB0 (bazë):	78.33%
+ Augmentation:	82.67% (+4.34pp)
+ Household Fine-tune:	88.83% (+6.16pp)
+ Garbage v2 Fine-tune:	92.17% (+3.34pp)
Totali:	+13.84pp

5. Rezultati Final

5.1 Saktësia totale

Metrika	Vlera
Saktësia totale (TTA)	92.17% (553/600)
Single-pass (pa TTA)	~91%
Macro F1-score	0.9236
Dataset testimi	600 foto reale, 100/klasë

5.2 Saktësia për klasë

Klasa	Saktë	Gabim	%
cardboard	92	8	92%
glass	95	5	95%

Klasa	Saktë	Gabim	%
metal	94	6	94%
paper	90	10	90%
plastic	92	8	92%
trash	90	10	90%
TOTAL	553	47	92.17%

5.3 Konfuzionet kryesore

- glass → plastic: 3 raste (xham i ngjashëm me plastikë)
- cardboard → trash: 4 raste (karton i shtypur/i ndotur)
- paper → cardboard: 5 raste (letër e trashë)
- trash → paper/plastic: të shpërndarë

5.4 Krahاسimi i modeleve mbi dataset-in real v2

Modeli	Saktësia
CNN Baseline	~30% (vlerësim)
MobileNetV2	~70% (vlerësim)
EfficientNetB0 (TrashNet only)	78.33%
EfficientNetB0 + Augmentation	82.67%
EfficientNetB0 + Household FT	88.83%
EfficientNetB0 + Garbage v2 FT	92.17%

6. Gjetjet Kryesore

6.1 Domain Shift — problemi kryesor

TrashNet trajnohet me foto studio (sfond i bardhë, ndriçim uniform). Dataset-i real ka sfonde komplekse, ndriçim të ndryshëm, objekte të paqëndrueshme. Kjo krijoi hendek të madh: EfficientNetB0 vetëm nga TrashNet → 78.33% real-world.

Zgjidhja: Fine-tuning progresiv me dataset-e reale (TACO → Household → Garbage v2) rriti saktësinë real-world me +13.84pp.

6.2 Data Augmentation

Konfirmoi hipotezën: +4.34pp real-world pa ndryshim arkitekture. Veçanërisht efektive për imazhe me sfonde të ndryshme.

6.3 Test-Time Augmentation (TTA)

+1-5pp pa ritrainim — teknikë e thjeshtë me ndikim real. Mesatarizimi i 5 pamjeve redukton ndjeshmërinë ndaj kornizimit.

6.4 Rezultate negative me vlerë akademike

- **EXP-006 (rembg):** Heqja e sfondit *dëmtoi* saktësinë (−2.56pp). Tregon se preprocessing naiv nuk funksionon gjithmonë.
- **EXP-010 (Ensemble):** Mesatarizimi i 3 modeleve dha rezultat më të keq se modeli më i mirë vetëm (−3.85pp). Modelet e dobëta "zvarrisin" të fortin.

6.5 Transfer Learning kundër CNN nga zero

Qasja	TrashNet Val
CNN nga zero	56.44%
MobileNetV2	87.13% (+30.69pp)
EfficientNetB0	89.90% (+33.46pp)

Transfer learning është qartësisht superior, veçanërisht kur dataset-i trajnimit është i vogël.

6.6 Klasa "trash" — sfida kryesore

Trash është klasa më e vështirë: 137 imazhe në TrashNet (vs 594 paper), kategori e paqartë vizualisht (objekte të ndryshme). Me fine-tuning, u rrit nga 52% → 90%.

7. Aplikacioni Web

U ndërtua një web aplikacion Flask me: - **Backend:** Python Flask, model EfficientNetB0 + TTA - **Frontend:** HTML/CSS/JavaScript, single-page - **Funksionalitete:** - Upload drag & drop i imazhit - Klasifikim real-time - Confidence score dhe bar chart për të 6 klasat - Tip riciklimi për klasën e predikuar - Badge me saktësinë e sistemit (92.2%)

Komanda për nisje:

```
cd waste-classification-master-thesis
source venv/bin/activate
python app.py
# Hap: http://127.0.0.1:5000
```

8. Pyetjet Hulumtuese — Përgjigjet

Q1: Sa ndryshon performanca TrashNet → real-world? EfficientNetB0 nga TrashNet vetëm: 89.90% TrashNet → 78.33% real-world (−11.57pp domain shift). Me fine-tuning progresiv mbyllet ky hendek: 92.17% real-world.

Q2: Cila qasje jep performancën më të mirë? EfficientNetB0 + Fine-tune Garbage v2 + TTA: **92.17%** — superior ndaj CNN bazike (+35.73pp) dhe MobileNetV2 (~+22pp).

Q3: Cilat klasa ngatërrohen më shpesh? Glass↔Plastic (ngjashmëri vizuale e materialit) dhe Trash↔klasat e tjera (kategori e paqartë). Analiza e gabimeve u bë për çdo klasë me emra specifike imazhesh.

9. Struktura e Projektit

```
waste-classification-master-thesis/
├─ app.py                                # Web app (Flask)
├─ requirements-app.txt                  # Dependencies minimale
├─ templates/index.html                 # Frontend UI
├─ src/
│   ├─ data/                            # Skripte përgatitje dataset-esh
│   │   ├─ prepare_garbage_v2.py
│   │   ├─ prepare_household.py
│   │   └─ ...
│   ├─ training/                        # Skripte trajnimi
│   │   ├─ train_garbage_finetune.py    # EXP-011
│   │   ├─ train_object_centric.py     # EXP-008
│   │   └─ ...
│   ├─ inference/
│   │   └─ tta_predict.py               # TTA inferim
│   └─ evaluation/
│       └─ evaluate_tta.py              # Evaluim real-world
├─ data/
│   ├─ real_test_dataset/               # 600 foto reale (held-out)
│   └─ garbage-v2-prepared/            # Dataset trajnimit
├─ results/
│   └─ efficientnet_garbage/            # Model final (~19 MB)
└─ docs/
    ├─ notes.md                         # Log i detajuar i eksperimenteve
    └─ progress_report.md               # Ky dokument
```

10. Teknologjitë e Përdorura

Teknologjia	Versioni	Roli
Python	3.9	Gjuha kryesore
TensorFlow / Keras	2.16.2	Framework deep learning
EfficientNetB0	—	Arkitektura kryesore
PIL / Pillow	11.3.0	Preprocessing imazhesh

Teknologjia	Versioni	Roli
NumPy	1.26.4	Operacione numerike
scikit-learn	1.6.1	Metrika evaluimi
Flask	3.1.3	Web backend
Matplotlib / Seaborn	—	Vizualizime

11. Gjendja aktuale dhe hapat e ardhshëm

Realizuar plotësisht:

-  CNN bazike nga zero (EXP-001)
-  Transfer learning MobileNetV2 dhe EfficientNetB0 (EXP-002, 003)
-  Data augmentation (EXP-004)
-  Fine-tuning me dataset-e të shumta (EXP-005, 007, 008, 011)
-  TTA — Test-Time Augmentation (EXP-009)
-  Eksperimente negative të dokumentuara (EXP-006, 010)
-  Dataset real 600 foto, i balancuar (100/klasë)
-  Evaluim final: 92.17% (553/600)
-  Analiza e gabimeve per klasë
-  Aplikacion web funksional
-  Log i detajuar i eksperimenteve (docs/notes.md)
-  README me udhëzime setup/run

Mbetet për thesis:

-  Shkrimi i kapitujve të dokumentit të temës
-  Analiza e literaturës (kapitulli teorik)
-  Diskutimi i rezultateve (interpretim akademik)
-  Konkluzionet dhe rekomandimet për punë të ardhshme

12. Konkluzion

Sistemi i zhvilluar arrin **92.17% saktësi** mbi 600 foto reale të mbledhura nga ambienti i përditshëm — rezultat konkurrues me literaturën ekzistuese, veçanërisht duke marrë parasysh vështirësinë e dataset-it real (sfonde komplekse, ndriçim i ndryshëm, objekte të dëmtuara).

Kontributi kryesor akademik: demonstrimi sistematik se si **fine-tuning progresiv me dataset-e të larmishme reale** mbyll hendekun e domain shift — nga 78.33% (EfficientNet bazik) në 92.17% (+13.84pp), duke i dhënë përgjigje konkrete pyetjeve hulumtuese të propozimit.

Ky raport u përgatit si përmbledhje e fazës eksperimentale të temës së masterit.
Kodi burimor i plotë ndodhet në: `waste-classification-master-thesis/`
(branch: dev)